

ACERO — Estado del sistema para revisión académica

Documento para un investigador senior / director de tesis

Escrito para obtener una segunda opinión experta. Objetivo declarado: no vender humo. Se describe qué hace el sistema, con qué garantías, sobre qué datos, y — con el mismo énfasis — dónde está el techo epistémico y qué NO puede afirmar todavía.

1. Qué es, en una frase

ACERO es un **sistema operativo de investigación computacional local, con el humano en el centro del control**, que recorre de forma autónoma el ciclo científico —literatura, hipótesis, obtención de datos reales, diseño y **ejecución de análisis**, síntesis y crítica adversarial— y produce un **dossier reproducible**. Su producto máximo es un *candidato a revisión humana*, nunca un "descubrimiento".

La novedad de la última etapa no es "más datos ni más agentes", sino una **constitución científica computable**: reglas de código que separan descubrimiento de confirmación, hacen explícitas las hipótesis causales, contabilizan todo el espacio de búsqueda, gradúan la independencia de la evidencia y **acotan la afirmación** que un resultado puede hacer.

2. Principios epistémicos (codificados, no aspiracionales)

1. **El LLM nunca es evidencia.** El modelo propone, razona y redacta; la evidencia proviene de código auditable sobre datos identificables.
 2. **Nada es un descubrimiento** hasta revisión humana experta y replicación independiente. El estado máximo del sistema es "candidato a preprint".
 3. **No se fabrican datos, citas, DOIs ni resultados.** Cada dato se descarga con petición real y queda con URL + bytes + SHA-256.
 4. **Los negativos se preservan**; un resultado sin prueba nula se degrada a inconcluso; un positivo exige una segunda implementación.
 5. **Reejecución ≠ replicación**; el sistema lo distingue por diseño.
 6. **El humano decide todo lo irreversible** (publicar, declarar hallazgo). El sistema prepara, nunca publica.
-

3. El ciclo de investigación

- **Hipótesis orientadas a descubrimiento**, con filtro de novedad (asentada / en debate / abierta / inexplorada) y ángulos (cruce de datos, caza de anomalías, predicción no probada).
- **Literatura real**: OpenAlex + arXiv + Crossref, lectura de PDF de texto completo, snowballing por referencias citadas, búsqueda semántica por *embeddings*, y **detección de retracciones** (probada con Wakefield 1998 → retractado).
- **Fábrica de experimentos** (el diferenciador técnico), con separación estricta de responsabilidades:
 1. PLAN (modelo): qué datasets públicos hacen falta (solo hosts en lista blanca).
 2. FETCH (código, sin el modelo): descarga y registra URL + bytes + SHA-256.

3. CODEGEN (modelo): script autocontenido; recibe el **esquema real** de columnas para no programar a ciegas; obliga a **controles nulos** y a un **discriminador**.
 4. RUN (sandbox): ejecución con **red deshabilitada**, límites de CPU/RAM, screening estático y bucle de reparación.
 5. VALIDATE + PACKAGE: veredicto `supports|refutes|inconclusive`; sin nulo → inconcluso; "supports" exige **verificación cruzada con 2ª implementación**; todo se empaqueta reproducible (script, datos, resultado, `run.sh`).
- **Síntesis** → Modelo del Mundo (creencias versionadas, nunca sobrescritas; confianza con máximo < 1) + **dossier** automático.
 - **Autonomía**: Motor de Misiones (investigar → proponer → ejecutar → sintetizar → bucle de rigor), watchdog de literatura, motor de anomalías → hipótesis nuevas.

4. La Constitución Científica Computable (novedad principal)

Paquete `src/acero/science/` — 13 módulos, ~70 pruebas deterministas. Todo **aditivo**: no altera el flujo que ya funcionaba.

Componente	Qué gobierna
Régimen A/B + pre-registro	Descubrimiento libre vs confirmación bloqueada. Plan congelado + hash sobre el contenido científico (detecta ediciones post-hoc). Prohíbe abrir datos confirmatorios sin protocolo congelado.
Search Space Ledger	Contabiliza TODO lo explorado (hipótesis/columnas/subsets/transformaciones/modelos/semillas/exclusiones) → <i>deuda de exploración</i> . Toda decisión tras ver los datos = exploratoria, por código.
Holdout sellado	Split determinista (aleatorio/temporal/por grupo) que solo se abre con un evento de <i>unblinding</i> ; el split por grupo evita fuga de entidad (sujeto/centro/scaffold).
Capa causal (CAUSA)	DAG + criterio <i>back-door</i> por d-separación + estimando explícito + detección de colisionadores/mediadores. Si no es identificable → prohíbe lenguaje causal .
Niveles de independencia (0–6)	Una 2ª implementación NO es independencia. Afirmación fuerte = método distinto y dataset independiente.
Claim Compiler	Evidencia → afirmación máxima permitida (asociado / predice / efecto-bajo-supuestos / replicado). Lintea sobreafirmaciones (<i>demuestra, confirma, causa, descubrimiento</i>).
Catálogo de nulos	Nulos que preservan estructura (etiqueta/bloque/sujeto/temporal/espacial...) y avisa cuándo una permutación simple infla los falsos positivos.
Simulation & Recovery Bench	Universos sintéticos con verdad conocida: mide FPR/potencia/sesgo y destapa cuándo un método se deja engañar por confusión, lote o fuga. Una metodología no descubre hasta pasar el bench.
Novedad (4 tipos) + ContributionScore	Bibliográfica/datos/metodológica/científica; "no encontrado" ≠ "nuevo"; contribución = novedad × evidencia × importancia × robustez × mecanismo.
Presupuesto de incertidumbre	9 dimensiones (medición, muestreo, modelo, preprocesamiento, selección, faltantes, generalización, causal, novedad), no un único número.
Panel adversarial plural	8 revisores con mandatos incompatibles; preserva el desacuerdo; los mandatos duros (estadístico/causalista/detective de datos) bloquean.
Máquina de estados	IDEA → ... → CANDIDATO_A_PREPRINT (tope ACERO) → revisión por pares / publicado / replicado externamente (solo agentes externos).

5. Prueba en vivo de la Constitución (evidencia, no promesa)

5.1 Primer estudio bajo régimen de confirmación (datos reales)

Validación de método sobre 910 moléculas reales de Caco-2 (Therapeutics Data Commons, descarga con hash).

Pregunta: ¿mayor polaridad molecular (proxy de TPSA) predice **menor permeabilidad**?

- Descubrimiento (n=619): efecto +0.746 logPapp, t=13.1.
- **Protocolo CONGELADO** (hash) antes de tocar el holdout.
- Holdout sellado (n=291) abierto **solo tras congelar** → régimen = confirmación.
- Confirmación: efecto +0.769, t=9.53, **misma dirección** con la regla congelada → estado **CONFIRMADO_EN_HOLDOUT**.

Honestidad: es una relación **ya conocida** (regla de Veber). Sirve para demostrar que el sistema **no infla** un resultado exploratorio a "confirmado" sin holdout, no para reclamar un hallazgo. El holdout es un split del mismo dataset, así que NO se reclama replicación independiente.

5.2 Panel adversarial plural en vivo (8 voces vía LLM)

Sobre ese mismo resultado, cada revisor en su carril:

- **Causalista** → **defectuoso [BLOQUEA]**: estimando asociacional; **confusión no controlada** (peso molecular, lipofilia, clase química).
- **Detective de datos**: sin auditoría de duplicados/sales/tautómeros → posible fuga entre splits.
- **Revisor de novedad**: **no novedoso** (recapitula TPSA / Lipinski-Veber).
- **Abogado del mecanismo alternativo**: modelos rivales (tamaño molecular; lipofilia).
- **Redactor hostil**: el abstract debe ser asociativo, no causal.
- Agregado: *en disputa*, **bloqueado por el mandato duro del causalista**.

El panel es **más exigente que un crítico único** y bloqueó el lenguaje causal — el tipo de disciplina que faltaba.

5.3 Otros resultados reales (etapas previas)

- **Astronomía (Fulton gap)**: refutación autónoma de una hipótesis nula con datos NASA reales (valle recuperado en $\sim 1.82 R_{\oplus}$). Sin "descubrimiento" declarado.
- **Genómica (EWAS Parkinson, GSE111629)**: matriz real de betas 485.512 CpGs $\times$ 572 muestras; t-test + FDR + permutación con λ_{gc} reportado.
- **Física cuántica**: señales iniciales contradichas por la verificación cruzada → reportado *inconclusive* en lugar de forzar un positivo.

6. Fuentes de datos (públicas, reales, sin llave de pago)

Bibliografía: OpenAlex, arXiv (PDF), Crossref (con retracciones). **Datos estructurados por dominio, con compuertas anti-contaminación cruzada**:

Dominio	Fuentes
Astronomía / física	NASA Exoplanet Archive (TAP), GWOSC, SILSO (solar)
Genómica / biomedicina	GEO (NCBI): matrices de expresión/metilación
Química — descriptores	PubChem (PUG-REST): MW, XLogP, TPSA, H-bond... (calculados)
Química — bioactividad	ChEMBL (EBI): IC50/Ki/EC50/Kd medidos con estructura
Química — ADME/Tox	TDC (22 datasets: Caco-2, solubilidad, hERG, BBB, CYP, DILI, LD50...) medidos
Cualquier campo	Zenodo, Figshare, Dryad

Integridad: lista blanca de hosts, procedencia con SHA-256, introspección de esquema real, compuerta por dominio (un proyecto de química nunca recibe datos de astronomía), regla de cruce por coordenadas/ID normalizado (no por nombre).

7. Autoevaluación honesta (contra las 11 dimensiones de un revisor externo previo)

Un revisor experto previo calificó el sistema en **7.4/10** ("la ingeniería madura más que la validación científica"). Tras construir la Constitución y probarla en vivo:

Dimensión	Antes	Hoy (honesto)
Honestidad epistemológica	9.3	9.5
Reproducibilidad computacional	8.7	8.8
Procedencia de datos	8.5	8.7
Automatización del ciclo	8.4	8.4
Análisis estadístico general	6.8	7.3
Inferencia causal	5.2	6.5
Control del espacio de búsqueda	5.5	7.0
Garantía de novedad	5.8	6.8
Validación externa independiente	4.5	5.3
Preparación para publicación	6.3	7.3
Descubrimientos defendibles	6.0	7.2

Global honesto: ~7.4 → ≈8.2.

8. Límites y riesgos que pedimos examinar

1. **La confirmación aún se demostró sobre un split del mismo dataset**, no sobre una cohorte independiente. `REPLICADO_EN_DATASET_INDEPENDIENTE` exige una 2ª fuente real.
2. **La capa causal está construida pero exige que se declaren DAGs** por hipótesis; hoy la mayoría de análisis son asociacionales (y el sistema lo dice).
3. **El panel plural corrió sobre un caso**; falta rodaje y calibración de sus umbrales de bloqueo.

4. **Novedad genuina:** distinguir "inexplorado" de "publicado pero no indexado" sigue siendo difícil (el revisor de novedad lo mitiga, no lo resuelve).
 5. **Dependencia del LLM** para redacción/razonamiento (nunca evidencia, pero sesga la formulación).
 6. **Autoevaluación no independiente:** por eso este documento.
-

9. Preguntas para el revisor

1. Dado el pipeline (datos con hash → nulos por estructura → discriminador → régimen de confirmación con protocolo congelado + holdout → panel plural con bloqueo causal → dossier), **¿qué falta para que un resultado positivo sea defendible ante un tribunal hostil de Nature/PRL?**
 2. ¿Qué exigiría además (pre-registro público, hold-out temporal, corrección por multiplicidad específica, análisis de sensibilidad, *selective inference*)?
 3. ¿Qué pregunta y en qué dominio ofrece la mejor relación "atacable con datos públicos" / "genuinamente abierta" para un **primer resultado publicable** (aunque sea un negativo robusto o un benchmark metodológico)?
 4. ¿La distinción reejecución/replicación y el techo "revisión humana" son garantías suficientes, o ve riesgos de sobreinterpretación o mal uso?
 5. Para pasar de dossier a preprint: ¿cómo estructuraría el crédito, la declaración de uso de IA (la IA nunca es autora) y la trazabilidad de datos para que sean irreprochables?
-

Resumen de una línea: **ACERO automatiza el trabajo pesado y reproducible de la investigación computacional sobre datos públicos, preservando negativos y sometándose a un panel adversarial plural que bloquea el lenguaje causal indebido; separa por código descubrimiento de confirmación y se detiene deliberadamente en el umbral del "descubrimiento", que reserva a la replicación y el juicio humano. Buscamos su criterio sobre si ese umbral está bien puesto y qué haría falta para cruzarlo con rigor.***