

ACERO — Tesis técnica del sistema

Un sistema operativo de investigación científica autónoma, local-first, con honestidad constitucional

Merari Acero · 10 de agosto de 2026 · ~52,000 líneas de código fuente, ~16,400 de tests, 180 commits

1. Tesis

ACERO es una máquina para explorar espacios de conocimiento enormes sin mentirse a sí misma. La apuesta central no es "un LLM que hace ciencia" — es una *arquitectura* donde múltiples agentes con oficios distintos producen, atacan y clasifican evidencia bajo reglas mecánicas que ninguno puede saltarse, con el humano como validador final e insustituible.

Tres decisiones fundacionales lo definen:

- 1. **El texto de un LLM nunca es evidencia.** Evidencia = ejecución verificada en sandbox, prueba mecánica (sympy/Z3), o contraejemplo concreto. Un párrafo convincente vale cero.
- 2. **La honestidad es estructural, no aspiracional.** No depende de que un prompt diga "sé honesto": hay compuertas (gate), disposiciones cerradas, registros inmutables y verificadores independientes que hacen que inflar un resultado sea *mecánicamente difícil*.
- 3. **El techo es humano.** El estado máximo que ACERO puede otorgar solo es "listo para revisión humana". Jamás declara resuelto un problema abierto; jamás publica solo.

2. Anatomía general

PORTAL (FastAPI + front vanilla, 127.0.0.1:8611/portal)
3 MODOS: Investigación · Aprender · Económico
CONSEJO (18 personajes = 18 módulos) ← BOHR dirige
MAQUINARIA EPISTÉMICA
gate constitucional · EVA · rivales · pre-registro · holdout
linaje de evidencia · grafo de independencia · nulos · CAUSA
MOTORES DE CIENCIA
math_probe · formal_verify (sympy) · proof_assistant (Z3)
frontier_toolkit · sat_escalation · patterns · spark · turing

INFRAESTRUCTURA
ledger (SQLite, genealogía) · sandbox (subproceso/docker)
TOOLBOX (catálogo LEGO) · providers LLM · knowledge_mesh
regla del 90% (RAM/VRAM) · selfeval/release gates

Todo pasa por el ledger. Cada acción de cada personaje escribe una fila tipada (kind) con actor, parent_id (genealogía hacia la hipótesis) y estado. El dashboard entero se deriva del ledger: si no está en el ledger, no ocurrió. Esto hace al sistema auditable por construcción — anti-HARKing estructural.

3. Los tres modos

Modo	Qué es	Motor
Investigación	El corazón: conjeturas → Consejo → evidencia → informe. Portada = el Consejo; cada personaje abre su tablero real.	investigator_bridge + bohr
Aprender	Tutor de 3 paneles (árbol de conceptos anidado + chat + lienzo KaTeX/Mermaid) que lleva de un tema general hasta la FRONTERA del conocimiento y desde ahí siembra investigaciones reales.	pedagogy/learning
Económico	Asesor de 3 paneles sobre las finanzas reales de NEXUS (conector integrations/nexus.py): ideas de crecimiento + loop de crítica adversarial.	portal/economics

Los tres comparten el mismo shell (chat izquierda + dashboard centro) y el mismo ledger.

4. El Consejo: 18 oficios

Fase creativa / planteamiento

- **Hilbert** — convierte temas en conjeturas PRECISAS y falsables (candidate).
- **Euler** — catálogo de métodos: qué técnica matemática aplica a qué problema.
- **Arquímedes** — catálogo de datasets y recursos computables.
- **Da Vinci** — diseña experimentos (fábrica: fetch confiable → codegen consciente del esquema → sandbox → reparación).
- **Ramanujan** — chispas laterales "¿y si...?" cuando hay FRONTERA declarada; lee el TOOLBOX y propone ideas con probabilidad, analogía y experimento barato (spark).
- **Mendeleev** — descubre patrones en datos verificados (§7) (pattern).

Fase de investigación / registro

- **Hipatia** — novedad multi-fuente: ¿ya se hizo? (arXiv/OpenAlex/Crossref vía knowledge_mesh) con juez clasificador (literature).
- **Tycho** — memoria de scripts que funcionaron (caché de Popper) — reintentos gratis.
- **Kepler** — cosecha anomalías de resultados → hipótesis nuevas.
- **Bohr** — el director (\$5) (decision).

Fase crítica / prueba

- **Popper** — ataque computacional masivo buscando contraejemplos (sandbox, aritmética exacta) (experiment, negative).
- **Euclides** — prueba SIMBÓLICA: identidades, desigualdades, sumas/productos telescópicos, límites (sympy con timeout duro en proceso hijo) (lemma).
- **Gödel** — prueba MECÁNICA SMT: $\forall/\exists$ sobre enteros/reales/booleanos (Z3 en proceso hijo, techo de días, latido cada minuto) (lemma).
- **Turing** — el hacker-matemático: escribe el experimento en Python, instala piezas que falten (pip/docker/Sage), lo corre, lee el error, repara y reintenta durante horas (build).
- **Aristóteles** — crítica hostil: reconstruye la afirmación exacta, busca alternativas no descartadas y qué la falsaría (critique).
- **Noether** — referee de journal: clasifica sin piedad teorema / evidencia / conjetura, ataca la novedad, exige chequeos faltantes. Arbitraje INTERNO — nunca sustituye al experto humano (review).

Publicación

- **Gauss** — empaqueta el dossier con evidencia y límites explícitos; estado máximo: needs_human_review (dossier).
- **Feynman** — la actitud hacker entre fases: interpreta el último resultado, refina bordes, reformula, propone la segunda jugada (reformulation).

5. Bohr: cómo decide (la pregunta central)

No hay pipeline. Existe un modo clásico legado (guion fijo), pero el vigente es **Bohr v2**: un bucle *decidir* → *ejecutar* → *observar* donde cada jugada se elige mirando los resultados REALES de las anteriores.

Entradas de cada decisión: (1) conocimiento del Consejo — quién es cada uno + catálogo TOOLBOX (incluye datos operativos como "PARI 7× para factorización masiva"); (2) la **premisa sellada** si existe — léida ANTES que todo; (3) el historial de jugadas con veredictos verificados; (4) presupuesto restante (200 jugadas / 7 días — topes de seguridad, no metrónomo).

Su system prompt (fiel): "Miras el ESTADO real y eliges la SIGUIENTE jugada del menú. Piensas: ¿qué sé ya? ¿qué me falta saber? ¿quién del Consejo me lo consigue más directo?" — con reglas de estilo: repetir jugada solo con argumentos distintos; segunda opinión (Aristóteles) antes de creer un positivo; frontera agotada → Ramanujan; chispa prometedora → Turing con horas; lema sin novedad no vale → Hipatia antes de Gauss; reformular sin nostalgia; "el tiempo NO es restricción, la deshonestidad SÍ".

Menú de 13 jugadas (cada una con "qué hace / cuándo"): hipatia, popper, feynman, godel, ramanujan, turing, aristoteles, kepler, mendeleev, noether, gauss, reiniciar, cerrar. La respuesta viene en JSON de esquema estricto (acción + razón + expectativa + parámetros específicos como presupuesto de Turing o dataset de Mendeleev) — la razón queda en la bitácora.

Salvaguardas mecánicas (código, no prompt): - Anti-bucle: 3 resultados idénticos consecutivos bloquean la 4ª repetición. - Disposiciones de cierre cerradas (verified / formally_supported / partial_progress / refuted / dropped / needs_human_review); inventar una la degrada a needs_human_review. - **Guardián de premisa:** todo reiniciar y toda reformulación se contrasta contra el sello; la deriva se registra (drift) y la alerta se inyecta al historial que Bohr lee. Guardián caído ≠ aprobación. - Latido: decidir (LLM) y demostrar (Z3) pueden tardar horas — ambos laten al tablero; "pensando" nunca es indistinguible de "colgado". - Ejecutor roto ≠ ciclo muerto; jugada fallida se registra y se sigue. - Al cerrar: informe-bitácora + **sugerencia automática de siguiente ronda** (hilos no explorados, pista pendiente, claim listo para lanzar).

6. La maquinaria epistémica (la constitución)

Esta capa existe porque los LLM se engañan con facilidad. Cada pieza nació de un modo de fallo observado:

Pieza	Contra qué defiende
Epistemic gate (motor + reglas por tipo: hipótesis, experimento, inferencia, publicación...)	promociones de estado sin evidencia suficiente
Pre-registro sellado + régimen A/B (CCC-1)	ajustar el protocolo después de ver resultados
Guardián de premisa	deriva silenciosa de la PREGUNTA misma entre rondas
Search Space Ledger	"encontré X" ocultando cuánto se buscó (deuda de exploración)
Holdout manager	contaminación confirmatoria (datos de confirmación inaccesibles hasta el final)
Linaje de evidencia + grafo de independencia	contar como "independientes" evidencias que comparten origen — independencia CALCULADA, no declarada

Pieza	Contra qué defiende
Catálogo de nulos por estructura	señales que también aparecen en datos aleatorizados
CAUSA (capa causal) + validación sustantiva de aristas	correlación vestida de causalidad
EVA (analista de vulnerabilidades epistémicas) + ClaimReconstructor	atacar una versión débil o distinta de la afirmación real
Teorías rivales (generador) + panel adversarial plural	enamorarse de la primera explicación
Genealogía anti-HARKing (ledger semántico)	reescribir la hipótesis para que "siempre fue" lo encontrado
Taxonomía de novedad + ContributionScore	vender lo ya conocido como nuevo (anti-Erdős gate)
Selfeval + baseline sellado	regresión de capacidad silenciosa (capacidad $\neq$ rendimiento de reloj)
Reliability : red team, mutation testing, calibración, scorecard	sobreconfianza sistemática
Publicación : attestation externa + paquete de verificación exportable	"confía en mí" — terceros pueden verificar sin ACERO

7. Mendeleev y el descubrimiento de patrones

El añadido más reciente (hoy). Pipeline: **FeatureLab** (representaciones derivadas controladas: log, razones, módulos — cada una con receta reproducible) → descubridor estadístico (correlaciones, invariantes, estabilidad bootstrap) → descubridor simbólico (gramática corta de leyes; gana el compromiso explicación/complejidad) → **consenso pesado por INDEPENDENCIA** (representaciones distintas de los datos, no número de métodos).

Contrato **PatternCandidate**: causalidad NO ESTABLECIDA siempre, rivales H1–H4 ($X \rightarrow Y$, $Y \rightarrow X$, causa común, artefacto), contraejemplos, procedencia completa (hash, semilla, parámetros). **Patrón $\neq$ descubrimiento**: convertirlo en conjetura es trabajo del Consejo. Su ficha muestra un mapa de grafos EN VIVO. GNN/autoencoders quedan condicionados a que un benchmark demuestre valor sobre lo clásico (y a la GPU, \$9).

8. Ciencias que puede investigar

- **Matemáticas** (la más profunda hoy): teoría de números (Erdős–Straus: paridad clásica lograda + descubrimiento de covering-sets verificado a 10^9), combinatoria/grafos (Caccetta–Häggkvist acotado: $n \leq 13$ PROBADO por Z3, $n=14$ en ataque), lógica/conteo (Z3), álgebra/análisis simbólico (sympy), geometría aritmética vía Sage enjaulado.

- **Astronomía** (plugin + lab): series de tiempo, inferencia sobre catálogos reales (caso vivo: valle de radios/metalicidad — cerró honesto en NO-GO).
- **Física** (plugin): identificación de dinámicas (SINDy-style), librería de términos, simetrías, derivaciones de primeros principios.
- **Química y Genética** (plugins con lab básico).
- **Dominio económico** (NEXUS, modo Económico).
- **Meta-ciencia**: benchmarks de sí mismo (recovery bench, integrity benchmark, gauntlets de caos/red-team/revisión externa).

La arquitectura de dominios es de **plugins con contratos** (domains/core): añadir una ciencia = implementar su lab + reglas de gate, no tocar el núcleo.

9. Recursos: la regla del 90%

Nacida de un incidente real (hoy): un cómputo sin límites agotó la RAM y apagó la PC. Ahora es ley del sistema:

- **RAM**: trabajos pesados con `nice`, workers acotados, y `guard` que los forma en FILA (pausa/reintento) si el sistema pasa del 90%.
 - **VRAM** (GPU RTX ~8GB, driver pendiente de activar): `gpu.py` con `status()` honesto, `wait_for_vram()` al 90%, y **protocolo de aviso previo** — ningún trabajo CUDA arranca sin confirmación humana (requiere reinicio para drivers).
 - **Criterio GPU**: tensores SÍ (embeddings, GNN, bootstraps masivos); lógica irregular NO (Z3, factorización, DP) — un solver no es un tensor.
 - **Eficiencia medida, no supuesta**: PARI 7× sympy en factorización (benchmark verificado, registrado en el TOOLBOX donde Bohr y Turing lo leen).
-

10. Estado actual (10-ago-2026)

Investigación Erdős–Straus (llave dinámica) — la prioridad estratégica: - Premisa SELLADA v1: $\text{porqué} = \text{fórmula } k(p)$ adaptativa con razón explicada; $\text{medio} = \text{ley de crecimiento de } \text{cover}(N)$; $\text{definición} = \text{criterio fuerte del divisor}$. - Dataset `cover_growth.json`: 15+ hitos, 7.3M primos duros procesados (rumbo a 10^{11} por etapas con revisión humana entre décadas); `cover greedy` 6→18 con tres hitos consecutivos en 18 — forma compatible con crecimiento logarítmico, pendiente de que Mendeleev lo dictamine con rivales. - Reconciliación honesta abierta: nuestro `cover_exact(10^5)=6` vs 5 externo (llavero acotado $k \leq 240$, documentado). - Ronda 5 EN VIVO con el guardián activo. Rondas 1–4: `partial_progress` honestos; la 4 fue cerrada por humano al detectar deriva de premisa — el incidente que motivó al guardián.

Caccetta–Häggkvist n=14: 5 semillas Z3 en paralelo (168h/240h de techo).

Backlog estratégico: publicación con attestation externa (pendiente de decisión humana sobre la NOTA); Hipatia→Obsidian con embeddings (plan LIT-1..4, primer uso real de la GPU); fase neuronal de Mendeleev condicionada a benchmark.

Calidad: suite unitaria en verde; matriz de aceptación 23/23; 5 supervisores/ crons autónomos con reglas de honestidad embebidas.

11. Lo que ACERO no hace (límites declarados)

1. No valida externamente: Noether es interna; la validación real es de expertos humanos (attestation existe pero requiere terceros).
2. No garantiza estrategia óptima: Bohr es un LLM bien instrumentado — sus salvaguardas son mecánicas, su criterio no.
3. El chequeo de deriva de premisa es por LLM (con el sello completo a la vista), no una verificación formal.
4. `cover_exact` es exacto respecto del llavero declarado, no absoluto.
5. Sin GPU activa aún; la fase de tensores está preparada pero no estrenada.
6. Los problemas ABIERTOS siguen abiertos: ACERO produce evidencia, lemas acotados y candidatos — el día que algo parezca más, el protocolo es frenar, verificar, arbitrar y llamar al humano. Por diseño.