


ACERO — Arquitectura del Consejo de Investigación

Documento para revisión por experto externo · 10 agosto 2026

ACERO es un sistema local-first de investigación matemática autónoma. Su núcleo es un **Consejo de 18 personajes-científicos**, cada uno un módulo de software real con un oficio, que atacan conjeturas bajo una **constitución de honestidad** cuyo techo es siempre la revisión humana. Nada se publica solo; el sistema jamás declara resuelto un problema abierto.

1. El flujo maestro



Principio rector: **el texto de un LLM nunca es evidencia**. Evidencia = ejecución verificada en sandbox, prueba mecánica (sympy/Z3), o contraejemplo concreto.

2. Los 18 del Consejo

#	Personaje	Oficio	Módulo real	Produce en el ledger
1	Hilbert		question_engine	

#	Personaje	Oficio	Módulo real	Produce en el ledger
		Plantea conjeturas precisas y falsables		candidate (hipótesis)
2	Euler	Cataloga técnicas y métodos aplicables	method_catalog	apoyo a decisión
3	Hipatia	Novedad: ¿ya se hizo? (multi-fuente: arXiv, etc.)	novelty_check	literature
4	Arquímedes	Catálogo de datasets/recursos	data resolvers	capacidad
5	Da Vinci	Diseño de experimentos	experiment_factory	experiment
6	Kepler	Cosecha anomalías → hipótesis nuevas	anomalies	candidate derivados
7	Tycho	Memoria de scripts que funcionaron (caché)	script_cache	reuso
8	Popper	Busca CONTRAEJEMPLOS computacionales	math_probe (sandbox)	experiment, negative
9	Euclides	Prueba simbólica (identidades, desigualdades, sumas)	formal_verify (sympy)	lemma
10	Gödel	Prueba mecánica SMT ($\forall/\exists$ sobre enteros/booleanos)	proof_assistant (Z3, en proceso hijo con techo de días y latido)	lemma
11	Aristóteles	Crítica hostil (revisor adversarial interno)	critic	critique
12	Feynman	Actitud hacker: interpreta, refina bordes, reformula	research_loop (HumanAttitude)	reformulation
13	Bohr	DIRECTOR: decide jugada a jugada (ver §4)	bohr.py	decision
14	Gauss	Empaqueta dossier publicable (techo: humano)	dossier	dossier
15	Ramanujan	Chispas laterales "¿y si...?" en fronteras	spark.py	spark
16	Turing	Programa/instala/corre/repara experimentos (horas)	turing.py + toolbox	build
17	Noether	Referee de journal (teorema vs evidencia vs conjetura; novedad) — arbitraje INTERNO, nunca sustituye al experto humano	noether.py	review
18	Mendeleev	Descubre patrones en datos verificados (ver §6)	patterns.py	pattern

3. Herramientas transversales

- **TOOLBOX (LEGO):** catálogo máquina-legible de piezas por nivel de evidencia (prueba-simbólica / prueba-mecánica / cálculo-experto / evidencia-numérica /

literatura). Incluye `ensure()` (instala por pip/docker) y `run_sage()` (Sage enjaulado en contenedor sin red).

- **Sandbox:** todo código generado corre en subprocesso aislado (timeout 1800s, 4GB, sin red). El código de los agentes jamás corre en el proceso del portal.
- **Escalera SAT** (`sat_escalation`): directo → portafolio de semillas → cube-and-conquer, institucionalizada como pieza.
- **Proveedores LLM:** Codex CLI (principal), Claude CLI, Ollama, mock para tests. Esquemas JSON estrictos en toda llamada estructurada.
- **Ledger:** SQLite con filas tipadas (`kind`), `actor`, `parent_id` (genealogía), estados. El dashboard entero se deriva del ledger — si no está en el ledger, no pasó.
- **Regla del 90% de recursos:** los trabajos pesados corren con `nice`, `workers` acotados y un guard que los FORMA EN FILA (pausa/reintento) si el sistema pasa del 90% de RAM. (Origen: un cómputo v1 sin límites apagó la máquina.)

4. ¿Quién orquesta? Bohr — y NO tiene flujo establecido

Hay dos modos, y esta distinción es central:

Modo clásico (legado): guion fijo Hipatia → Popper → Feynman → Gödel → Aristóteles → Gauss. Existe y funciona, pero es rígido.

Modo Bohr v2 (el vigente): NO hay pipeline. Bohr recibe: (1) su conocimiento del Consejo (quién es cada uno + el catálogo de piezas), (2) la premisa sellada si existe, (3) el HISTORIAL de jugadas con sus resultados REALES verificados, y (4) el presupuesto restante. Con eso **decide la siguiente jugada él solo**, jugada a jugada, vía una llamada LLM con esquema estricto. Puede repetir a un personaje con otro ángulo, pedir segunda opinión, darle horas de cómputo a Turing, reformular el enunciado (reiniciar) o cerrar honesto. Cada decisión queda en el ledger con su porqué.

Las instrucciones EXACTAS de Bohr (traducción fiel del system prompt)

Eres Niels Bohr dirigiendo el Consejo de ACERO. Tu papel: el humano que controla el flujo. Miras el ESTADO real (historial de jugadas y sus resultados VERIFICADOS) y eliges la SIGUIENTE jugada del menú. Piensas en términos de: ¿qué sé ya? ¿qué me falta saber? ¿quién del Consejo me lo consigue más directo?

Estilo de dirección: - Repite una jugada SOLO con argumentos distintos (otro ángulo, otro presupuesto). - Pide segunda opinión (Aristóteles) antes de creerte cualquier resultado positivo. - Si el camino directo está agotado o PROBADO imposible, no insistas: Ramanujan. - Una chispa prometedora merece cómputo de verdad: Turing con presupuesto generoso. - Un lema logrado no vale nada sin novedad: Hipatia lo dictamina ANTES de Gauss. - Reformular está permitido — abandona enunciados muertos sin nostalgia. - El tiempo NO es restricción; la deshonestidad SÍ. Cierra solo con disposición honesta.

CONSTITUCIÓN (innegociable): - JAMÁS declares resuelto un problema abierto. La validación final es HUMANA. - Texto de LLM no es evidencia. Evidencia = ejecución verificada o prueba mecánica. - Si nada maduró, 'needs_human_review' es un cierre digno — inflar es el único fracaso.

El menú de jugadas (cada una con "qué hace" y "cuándo usarla")

Jugada	Hace	Cuándo
hipatia	busca en literatura si ya existe	antes de invertir; tras un lema
popper	ataque computacional buscando contraejemplos	enunciado nuevo o refinado
feynman	interpreta el último resultado, refina bordes, reformula	ataque terminó y no es obvio qué sigue
godel	intento de PRUEBA mecánica (sympy/Z3)	sobrevivió ataques y huele a demostrable
ramanujan	chispas laterales "¿y si...?" con el catálogo LEGO	FRONTERA: métodos directos agotados
turing	programa, instala piezas, corre, repara (minutos→horas que Bohr fija)	idea concreta que necesita cómputo serio
aristoteles	crítica hostil del estado actual	antes de creerse un resultado
kepler	cosecha anomalías → hipótesis nuevas	experimentos con discrepancias
mendeleev	busca ESTRUCTURA en datos verificados (representaciones, leyes)	hay tabla de observaciones ≥ 5 filas y la pregunta es "¿qué estructura hay?"
noether	arbitraje de referee (interno)	resultado maduro que aspira a nota
gauss	empaqueta dossier	resultado verificado + novedad dictaminada
reiniciar	adopta enunciado nuevo	el actual se agotó, la reformulación abre camino
cerrar	disposición HONESTA + resumen	logrado, agotado, o toca decisión humana

Salvaguardas mecánicas del bucle (código, no prompt)

- **Guard anti-bucle:** 3 repeticiones consecutivas con resultado idéntico bloquean la 4ª — Bohr debe cambiar de jugada.
 - **Disposiciones cerradas:** solo puede cerrar con una disposición del conjunto honesto (verified / formally_supported / partial_progress / refuted / dropped / needs_human_review...). Una disposición inventada se degrada a needs_human_review.
 - **Guardián de premisa (on_restart):** todo "reiniciar" y toda reformulación de Feynman se contrasta contra la premisa sellada; la deriva se marca en el ledger (drift) y la ALERTA se anexa al historial que Bohr lee en la siguiente decisión.
 - **Latido:** decidir y demostrar pueden tardar horas; ambos laten al tablero para que "pensando" nunca sea indistinguible de "colgado".
 - **Ejecutor roto $\neq$ ciclo muerto:** una jugada que lanza excepción se registra y el ciclo continúa.
-

5. El guardián de premisa (jerarquía)

Al abrir una investigación se sella: **PORQUÉ** (objetivo irrenunciable), **MEDIO** (instrumental) y **DEFINICIONES operativas exactas**. El sello es inmutable (resellar crea versión). Bohr lo lee antes que todo su conocimiento. Origen: en la investigación de Erdős–Straus, la definición fuerte (criterio del divisor) se degradó entre rondas a una condición trivial sin que nadie lo decidiera; una ronda entera atacó la cerradura equivocada. Es el pre-registro (que ACERO ya usaba para protocolos) aplicado a la pregunta misma. No bloquea: hace la deriva VISIBLE y la convierte en decisión humana explícita.

6. Mendeleev — patrón $\neq$ descubrimiento

Pipeline: **FeatureLab** (representaciones derivadas controladas: log, razones, módulos..., cada una con receta reproducible) $\rightarrow$ descubridor estadístico (correlaciones, invariantes, estabilidad bootstrap) $\rightarrow$ descubridor simbólico (gramática corta de leyes; manda el compromiso explicación/complejidad) $\rightarrow$ **consenso pesado por INDEPENDENCIA**: `independent_views` cuenta representaciones distintas de los datos, no métodos — dos métodos sobre la misma matriz son la misma foto. Todo candidato lleva: causalidad NO ESTABLECIDA, rivales H1–H4 ($X \rightarrow Y$, $Y \rightarrow X$, causa común, artefacto), contraejemplos, y procedencia completa (hash del dataset, semilla, parámetros). Convertir un patrón en conjetura es trabajo del Consejo (Popper/Gödel/gate), nunca de Mendeleev. Su ficha en el portal muestra un mapa de grafos EN VIVO (patrones $\leftrightarrow$ variables).

7. Límites conocidos (para el ojo del experto)

1. **El chequeo de deriva es por LLM**, no mecánico: el guardián puede fallar en sutilezas. Mitigación: guardián caído $\neq$ aprobación; el sello viaja completo.
 2. **`cover_exact` es exacto respecto del llavero $k \leq 240$** — una llave óptima mayor no se ve. El límite va declarado en cada fila del dataset.
 3. **El arbitraje de Noether es interno**: nunca sustituye revisión externa real.
 4. **Bohr es un LLM decidiendo**: sus jugadas son tan buenas como su contexto; las salvaguardas son mecánicas pero la estrategia no lo es.
 5. **Los descubridores de Mendeleev son clásicos** (sin GNN) por diseño: entran solo si un benchmark demuestra valor añadido sobre lo clásico.
 6. **`holds_empirically` jamás se auto-promueve** a verified; la promoción es humana.
-

8. Estado vivo (al corte de este documento)

- Investigación Erdős–Straus con premisa sellada v1 (llave dinámica $k(p)$ como porqué; criterio del divisor como definición). Ronda 5 en curso.
- Dataset `cover_growth.json`: 13 hitos hasta 10^9 (extendiéndose a 10^{12}), 1.59M primos duros con el criterio fuerte; cover greedy 6→18. Discrepancia documentada con la tabla externa (6 vs 5 en 10^5 , llavero acotado).
- Portafolio Caccetta–Häggkvist $n=14$: 5 semillas Z3 en paralelo (techos 168h/240h).